

Classificação Tomografia

Acadêmico: Thiago Fernando Rech

CNN

Definição:

- Rede Neural Convolucional (CNN) é uma arquitetura de aprendizado profundo especializada em visão computacional.

Estrutura Básica:

- Camadas de convolução para detectar padrões.
- Camadas conectadas para classificação final.

Exemplo Prático:

- Utilizada em reconhecimento de imagem, detecção de objetos e classificação de imagens.

ResNet 18

Definição:

- ResNet-18 é uma arquitetura de Rede Neural Profunda, especialmente projetada para tarefas de classificação de imagens.

Características Principais:

- Utiliza blocos residuais para facilitar o treinamento de redes mais profundas.
- Arquitetura com 18 camadas, proporcionando um equilíbrio entre desempenho e eficiência computacional.

Vantagens da ResNet-18:

- Resolução do problema de desaparecimento de gradientes através da introdução de conexões residuais.
- Melhoria na eficiência do treinamento de redes mais profundas.

Desempenho em Tarefas Práticas:

- Amplamente empregada em competições de visão computacional e conjunto de dados ImageNet.
- Eficiente para tarefas como reconhecimento de objetos e classificação de imagens em geral.

VGG 16

VGG16 é uma arquitetura de Rede Neural Convolutacional (CNN) conhecida por sua profundidade e simplicidade, desenvolvida para tarefas de classificação de imagens.

Principais Características:

- Consiste em 16 camadas, incluindo 13 camadas convolucionais e 3 camadas totalmente conectadas.
- Foi proposta pela Visual Geometry Group (VGG) na Universidade de Oxford.

Estrutura Simples e Profunda:

- Abordagem de convoluções consecutivas com pequenos filtros (3x3) para aprender características complexas.
- Utiliza pooling máximo para reduzir a dimensionalidade e preservar características essenciais.

Desempenho e Aplicações:

- Destaca-se em tarefas de classificação de imagens, reconhecimento de objetos e transferência de aprendizado.
- Amplamente utilizada como referência em pesquisas e competições de visão computacional.

AlexNet

AlexNet é uma arquitetura pioneira de Rede Neural Convolutacional (CNN), marcando um avanço significativo na competição ImageNet em 2012 para tarefas de classificação de imagens.

Principais Contribuições:

- Desenvolvida por Alex Krizhevsky, Ilya Sutskever e Geoffrey Hinton.
- Venceu o desafio ImageNet com uma margem significativa, demonstrando a eficácia de CNNs em tarefas de visão computacional.

Características Distintas:


- Estrutura profunda com o uso de 8 camadas.
- Aplicação inovadora de técnicas como ReLU (Rectified Linear Unit) para introduzir não linearidades.
- Introduziu conceitos como Dropout para combater o sobreajuste.
- Utilizou técnicas de data augmentation para aumentar a diversidade do conjunto de treinamento.
- Estabeleceu o caminho para o desenvolvimento de arquiteturas mais profundas.
- Inspirou avanços subsequentes em visão computacional e redes neurais profundas.

Dataset: Brain tumors 256x256

- Total de Imagens: 3096
- Treinamento: 80%
- Validação: 20%
- Classes: glioma, meningioma, normal, pituitary


Dataset Treinamento

- glioma: 720;
- meningioma: 730;
- normal: 350;
- pituitary: 675;






Dataset Validação

- glioma: 181;
- meningioma: 183;
- normal: 88;
- pituitary: 169;






Resultados CNN

```
78/78 [=====] - 173s 2s/step - loss: 1.1803 - accuracy: 0.4788 - val_loss: 0.8326 - val_accuracy: 0.6425
Epoch 2/6
78/78 [=====] - 170s 2s/step - loss: 0.6583 - accuracy: 0.7438 - val_loss: 0.5890 - val_accuracy: 0.7697
Epoch 3/6
78/78 [=====] - 172s 2s/step - loss: 0.3211 - accuracy: 0.8877 - val_loss: 0.5815 - val_accuracy: 0.8052
Epoch 4/6
78/78 [=====] - 171s 2s/step - loss: 0.1640 - accuracy: 0.9438 - val_loss: 0.6794 - val_accuracy: 0.8003
Epoch 5/6
78/78 [=====] - 170s 2s/step - loss: 0.0970 - accuracy: 0.9701 - val_loss: 0.7785 - val_accuracy: 0.8357
Epoch 6/6
78/78 [=====] - 170s 2s/step - loss: 0.0334 - accuracy: 0.9919 - val_loss: 0.8796 - val_accuracy: 0.8374
```




Resultados ResNet18


```
Epoch 46 running
[Train #47] Loss: 0.0009 Acc: 98.1414% Time: 821.6457s
[Validation #47] Loss: 0.0026 Acc: 94.6860% Time: 823.9497s
Epoch 47 running
[Train #48] Loss: 0.0009 Acc: 98.3030% Time: 839.1417s
[Validation #48] Loss: 0.0027 Acc: 95.0081% Time: 841.4237s
Epoch 48 running
[Train #49] Loss: 0.0009 Acc: 97.8586% Time: 856.6187s
[Validation #49] Loss: 0.0026 Acc: 95.4911% Time: 859.0757s
Epoch 49 running
[Train #50] Loss: 0.0011 Acc: 97.9798% Time: 874.2337s
[Validation #50] Loss: 0.0027 Acc: 95.0081% Time: 876.6087s
```




Resultados VGG16





```
[Train #16] Loss: 0.0023 Acc: 94.9091% Time: 11466.0870s  
[Validation #16] Loss: 0.0028 Acc: 95.0081% Time: 11501.3265s  
Epoch 16 running  
[Train #17] Loss: 0.0030 Acc: 92.8485% Time: 12106.2472s  
[Validation #17] Loss: 0.0033 Acc: 93.8808% Time: 12136.1127s  
Epoch 17 running  
[Train #18] Loss: 0.0023 Acc: 94.9899% Time: 12800.0749s  
[Validation #18] Loss: 0.0021 Acc: 95.9742% Time: 12835.3475s  
Epoch 18 running  
[Train #19] Loss: 0.0023 Acc: 94.9899% Time: 13440.4896s  
[Validation #19] Loss: 0.0056 Acc: 92.1095% Time: 13470.4670s  
Epoch 19 running  
[Train #20] Loss: 0.0023 Acc: 94.5859% Time: 14133.8916s  
[Validation #20] Loss: 0.0041 Acc: 94.6860% Time: 14169.1166s
```



Resultados AlexNet



```
[Train #16] Loss: 0.0088 Acc: 88.6869% Time: 285.7717s
[Validation #16] Loss: 0.0053 Acc: 94.5250% Time: 287.8907s
Epoch 16 running
[Train #17] Loss: 0.0086 Acc: 89.2929% Time: 303.9559s
[Validation #17] Loss: 0.0108 Acc: 88.4058% Time: 306.1259s
Epoch 17 running
[Train #18] Loss: 0.0080 Acc: 89.9394% Time: 322.1776s
[Validation #18] Loss: 0.0096 Acc: 90.6602% Time: 324.2596s
Epoch 18 running
[Train #19] Loss: 0.0079 Acc: 90.0606% Time: 340.1988s
[Validation #19] Loss: 0.0081 Acc: 91.3043% Time: 342.3288s
Epoch 19 running
[Train #20] Loss: 0.0080 Acc: 90.0202% Time: 358.2356s
[Validation #20] Loss: 0.0080 Acc: 92.2705% Time: 360.4486s
```



Conclusão

O modelo CNN básico foi o que mostrou o pior desempenho entre os demais, este com 6 épocas apresentou uma acurácia de 83% na validação. Com um número maior de épocas o resultado caiu drasticamente, tornando inviável um treinamento com um número maior que 6 épocas;

Dentre os demais modelos obteve-se uma acurácia acima de 90% na validação em todos os modelos.

O modelo ResNet inicialmente foi treinado com 20 épocas como o VGG16 e o AlexNet. Este apresentou uma acurácia de 94% com 20 épocas, um novo teste foi feito com 50 épocas apresentando uma acurácia de 95% na validação, sendo superior ao VGG16 com acurácia de 94.68%.

Sendo assim considerando a acurácia na validação e o tempo de treinamento a ResNet se mostrou superior a AlexNet em validação e superior ao VGG16 em custo computacional em escala de tempo e na acurácia da validação